Problématique

La tuberculose peut être détectée à partir de l'analyse acoustique de la toux grâce à l'intelligence artificielle. Certaines études ont obtenu de très bons résultats, mais des études plus récentes montrent que ces résultats peuvent fortement diminuer lorsque les données utilisées pour tester le modèle proviennent d'un **autre appareil, d'un autre lieu ou d'une autre population**.

Cela signifie que le modèle peut parfois apprendre des caractéristiques liées à l'appareil ou au lieu d'enregistrement au lieu d'apprendre les véritables caractéristiques sonores liées à la tuberculose.

Le problème est donc de savoir si l'on peut développer un modèle capable de **reconnaître les signes acoustiques réellement liés à la tuberculose**, et qui reste efficace même lorsque les conditions d'enregistrement changent.

Question de recherche :

Peut-on développer un modèle d'analyse de la toux capable de détecter la tuberculose de manière fiable, même lorsque les enregistrements proviennent de différents appareils, lieux et populations ?

Questions secondaires

- Le modèle reconnaît-il réellement la tuberculose ou reconnaît-il surtout l'appareil ou le lieu d'enregistrement ?
- Les résultats du modèle restent-ils fiables lorsque les données viennent d'un autre site ou d'un autre pays ?
- Le modèle basé sur la toux apporte-t-il une information supplémentaire par rapport à des informations cliniques simples comme l'âge et les symptômes ?

Test de référence

Pour savoir si le modèle détecte correctement la tuberculose, nous utiliserons comme référence les tests microbiologiques utilisés pour confirmer la maladie .

Solution

Nous proposons de développer un système capable d'analyser la toux pour aider au dépistage de la tuberculose.

L'objectif principal n'est pas seulement d'obtenir une bonne performance sur les données d'entraînement, mais surtout de vérifier que le modèle reste fiable lorsqu'il est utilisé avec un

autre appareil, dans un autre site ou sur une autre population.

La solution sera organisée en cinq étapes :

1. Utilisation de plusieurs jeux de données

Nous utiliserons au moins deux jeux de données indépendants parmi :

CODA ;

TBscreen ;

Zambia/CIDRZ.

Ces jeux de données ont été enregistrés dans différents pays, sites et avec différents appareils.

Le modèle sera entraîné sur un premier jeu de données et testé sur un autre jeu qu'il n'a jamais vu. Cela permettra de vérifier sa capacité à généraliser à de nouvelles conditions.

2. Préparation des données et entraînement du modèle

Une préparation particulière des données sera réalisée afin d'éviter que le modèle apprenne des informations liées à l'appareil ou au lieu d'enregistrement au lieu des caractéristiques de la toux liées à la tuberculose.

Nous allons notamment :

équilibrer les données en tenant compte du site, de l'appareil et du statut TB ;

limiter les fréquences audio utilisées à 8 kHz maximum afin de réduire l'influence des caractéristiques propres aux appareils ;

isoler autant que possible l'événement de toux et réduire les bruits de fond ;

entraîner le modèle avec des enregistrements provenant de plusieurs appareils afin de tester sa capacité à fonctionner avec un appareil qu'il n'a jamais rencontré pendant l'entraînement.

3. Détection des raccourci appris par le modèle

Une partie importante du projet sera de vérifier ce que le modèle apprend réellement.

Nous utiliserons des représentations audio (embeddings) obtenues avec des modèles comme CLAP ou OPERA. Ces représentations seront analysées et visualisées afin de voir si les données se regroupent principalement :

selon le statut TB ;

selon le site d'enregistrement ;

ou selon l'appareil utilisé.

Nous vérifierons aussi si les probabilités prédites par le modèle suivent simplement la prévalence de la tuberculose dans chaque site ou pays. Une forte relation entre les deux pourrait indiquer que le modèle utilise le site comme raccourci au lieu d'identifier réellement la maladie.

Ces vérifications feront partie du processus d'évaluation du modèle et ne seront pas réalisées uniquement à la fin.

4. Comparaison avec un modèle clinique simple

Le modèle basé sur la toux sera comparé à une baseline clinique utilisant uniquement des informations simples sur le patient :

âge, sexe, durée de la toux, fièvre, perte de poids, sueurs nocturnes, statut VIH et tabagisme.

Les deux modèles seront évalués avec le même protocole de validation externe.

L'objectif est de vérifier si l'analyse acoustique de la toux apporte une information supplémentaire par rapport aux données cliniques simples.

5. Validation rigoureuse

Les données seront toujours séparées au niveau du patient et non au niveau de chaque toux.

En effet, un même patient peut fournir plusieurs enregistrements de toux. Mettre certaines toux du même patient dans l'entraînement et d'autres dans le test pourrait donner des résultats artificiellement élevés.

La performance principale du projet sera donc mesurée sur des données externes, c'est-à-dire sur des données provenant d'un jeu de données différent de celui utilisé pour l'entraînement.

La performance interne servira seulement de contrôle, tandis que la validation externe sera le véritable critère de réussite.

Besoins fonctionnels

1. Le système doit pouvoir recevoir un enregistrement audio de toux et donner une estimation : tuberculose probable, ou non.
2. Le système doit pouvoir s'entraîner à partir de plusieurs groupes de données déjà existants (des enregistrements de toux venant de différents pays et de différents

téléphones).
3. Le système doit pouvoir être testé sur un groupe de données complètement différent de celui utilisé pour l'entraînement, pour vérifier s'il fonctionne encore une fois « sorti de son contexte habituel ».
4. Le système doit pouvoir vérifier automatiquement, après chaque test, s'il a vraiment appris à reconnaître la maladie — ou s'il s'est simplement basé sur des indices qui n'ont rien à voir avec la maladie, comme le type de téléphone ou le pays d'où vient l'enregistrement.
5. Le système doit pouvoir comparer ses résultats à une méthode simple qui n'utilise aucun son, seulement des informations de base sur le patient (âge, fièvre, depuis combien de temps il tousse…), pour vérifier que le son apporte vraiment quelque chose en plus.
6. Le système doit garantir qu'un même patient n'apparaît jamais à la fois dans les données utilisées pour apprendre et dans celles utilisées pour tester, afin que les résultats soient fiables et non faussés.
7. Le système doit pouvoir produire, à la fin, un rapport clair indiquant : la fiabilité réelle du modèle, s'il « triche » ou non, et dans quelles conditions on peut lui faire confiance.

Besoins non-fonctionnels

1. Le système doit donner ses résultats avec une marge d'erreur, jamais un chiffre seul présenté comme certain.
2. Le système doit pouvoir être relancé par une autre personne, avec les mêmes données, et donner les mêmes résultats.
3. Le système doit permettre de comprendre pourquoi il a donné tel résultat, pas seulement afficher une réponse finale sans explication.
4. Le système doit traiter les données des patients avec précaution, même si elles sont publiques et anonymisées.
5. Le système doit pouvoir fonctionner sur un ordinateur portable normal ou un service gratuit en ligne, sans matériel coûteux.
6. Le système doit être écrit de façon claire et organisée, pour qu'une autre personne puisse le reprendre facilement plus tard.
7. Le système doit pouvoir accueillir une nouvelle base de données dans le futur sans devoir tout reconstruire.

Ressources

Bases de données

- TBscreen : https://zenodo.org/records/10431329
- Zambia / CIDRZ : https://www.kaggle.com/datasets/googlehealthai/google-health-ai
- CODA : https://www.synapse.org/Synapse:syn31472953

Code de référence

- Pipeline complet de l'étude EPFL (à reproduire/adapter) : https://github.com/esl-epfl/tb-cough-generalization

Modèles pré-entraînés

- CLAP (Microsoft) : https://github.com/microsoft/CLAP
- OPERA (spécifique aux sons respiratoires) : https://github.com/evelyn0414/OPERA